

Concentración IA Avanzada para la Ciencia de Datos

Tarea I: Vectorización

Fecha de entrega: 07 de octubre de 2022.

Integrantes:

A01652277 | Samuel Méndez Villegas

A01653115 | Iker Ledesma Durán

A01731813 | Mariana Pérez Carmona

A01734337 | Nancy Lesly Segura Cuanalo

A01750164 | Paul Martín García Morfín

1. **Función de costo:** Como vimos en clase, la función de costo del modelo de regresión logística es la siguiente:

$$C(w) = -\frac{1}{n} \sum_{i=1}^n y_i \log(h(x_i)) + (1 - y_i) \log(1 - h(x_i)).$$

Demuestra que la siguiente expresión es equivalente.

$$C(w) = -\frac{1}{n} \left(y^T \log(h(Xw)) + (1 - y)^T \log(1 - h(Xw)) \right).$$

Ecuación 1

Se usa la convención en la que todos los vectores son vectores columna. X es la matriz de datos cuyas filas son los datos x_i^T . Partiendo de que una función escalar que se aplica a un vector se aplica a la entrada, tenemos:

$$\begin{aligned} C(w) &= -\frac{1}{n} \sum_{i=1}^n y_i \log(h_w(x_i)) + (1 - y_i) \log(1 - h_w(x_i)) \\ &= -\frac{1}{n} \left(y^T \log(h(Xw)) + (1^T - y^T) \log(1 - h(Xw)) \right). \end{aligned}$$

Finalmente:

$$C(w) = -\frac{1}{n} \left(y^T \log(h(Xw)) + (1 - y)^T \log(1 - h(Xw)) \right).$$

2. **Gradiente de la función de costo:** tomando como punto de partida la ecuación (1), demuestra que el gradiente de dicha función está dado por:

$$\nabla C(w) = \frac{1}{n} X^T (h(Xw) - y).$$

La derivada, que es el Jacobiano, de C con respecto a w se obtiene utilizando la regla de la cadena. Se tiene que:

$$D_v f(Mv) = \text{diag}(f'(Mv))M$$

donde,

diag se refiere a la matriz diagonal

M es una matriz

v es un vector columna

Calculando:

$$\begin{aligned} nD_w C &= -y^T [\text{diag}((1-h)(Xw))]X - (1-y)^T [\text{diag}(-h(Xw))]X. \\ &= -y^T X + 1^T [\text{diag}(h(Xw))]X. \\ &= -y^T X + (h(Xw))^T X. \\ (D_w C)^T &= \frac{1}{n} X^T (h(Xw) - y). \end{aligned}$$

Finalmente:

$$\nabla C(w) = \frac{1}{n} X^T (h(Xw) - y).$$

Si quisiéramos obtener el gradiente de la función de costo expresada de forma tradicional, se calculan las derivadas parciales:

$$\begin{aligned} \frac{\partial C(w)}{\partial w_j} &= \frac{\partial}{\partial w_j} - \frac{1}{n} \sum_{i=1}^n [y_i \log(h(x_i)) + (1-y_i) \log(1-h(x_i))]. \\ &= -\frac{1}{n} \sum_{i=1}^n \left[y_i \frac{\partial}{\partial w_j} \log(h(x_i)) + (1-y_i) \frac{\partial}{\partial w_j} \log(1-h(x_i)) \right]. \end{aligned}$$

Se aplica regla de la cadena:

$$= -\frac{1}{n} \sum_{i=1}^n \left[y_i \frac{\frac{\partial}{\partial w_j} h(x_i)}{h(x_i)} + (1-y_i) \frac{\frac{\partial}{\partial w_j} (1-h(x_i))}{1-h(x_i)} \right].$$

Sustituyendo $h(x) = \sigma(wx)$:

$$= -\frac{1}{n} \sum_{i=1}^n \left[y_i \frac{\frac{\partial}{\partial w_j} \sigma(wx_i)}{h(x_i)} + (1 - y_i) \frac{\frac{\partial}{\partial w_j} (1 - \sigma(wx_i))}{1 - h(x_i)} \right].$$

Derivada de la función sigma:

$$\frac{d}{dx} \sigma(x) = \frac{d}{dx} \left(\frac{1}{1 + e^{-x}} \right) = \sigma(x)(1 - \sigma(x)).$$

Entonces:

$$= -\frac{1}{n} \sum_{i=1}^n \left[y_i \frac{\sigma(wx_i)(1 - \sigma(wx_i)) \frac{\partial}{\partial w_j} \sigma(wx_i)}{h(x_i)} \right. \\ \left. - (1 - y_i) \frac{\sigma(wx_i)(1 - \sigma(wx_i)) \frac{\partial}{\partial w_j} \sigma(wx_i)}{1 - h(x_i)} \right].$$

Reemplazando $\sigma(wx) = h(x)$:

$$= -\frac{1}{n} \sum_{i=1}^n \left[y_i \frac{h(x_i)(1 - h(x_i)) \frac{\partial}{\partial w_j} \sigma(wx_i)}{h(x_i)} - (1 - y_i) \frac{h(x_i)(1 - h(x_i)) \frac{\partial}{\partial w_j} \sigma(wx_i)}{1 - h(x_i)} \right].$$

Simplificando:

$$= -\frac{1}{n} \sum_{i=1}^n [y_i(1 - h(x_i))x_i - (1 - y_i)h(x_i)x_i]. \\ = -\frac{1}{n} \sum_{i=1}^n [y_i - y_i h(x_i) - h(x_i) + y_i h(x_i)]x_i. \\ = -\frac{1}{n} \sum_{i=1}^n [y_i - h(x_i)]x_i.$$

Finalmente:

$$\nabla C(w) = \frac{1}{n} \sum_{i=1}^n [h(x_i) - y_i]x_i.$$

Como se puede observar, se llegó a la misma expresión que se tiene en la forma matricial.

$$\nabla C(w) = \frac{1}{n} \sum_{i=1}^n [h(x_i) - y_i] x_i = \frac{1}{n} X^T (h(Xw) - y).$$

De esta manera, se comprueba que los cálculos realizados son correctos y las expresiones son equivalentes.

Referencias

Otero, F. (2022). Inteligencia Artificial para la Ciencia de Datos. Regresión Logística. [diapositivas]. Facultad de Ingeniería y Ciencias, Tecnológico de Monterrey.

Matrix Calculus [PDF].

Función de costo de regresión logística y su fórmula de descenso de gradiente. (2020). Programador Clic. <https://programmerclick.com/article/61431910230/>

Cálculo matricial para el aprendizaje profundo. (2020). Programador Clic. <https://programmerclick.com/article/6587987603/>

Matrix notation for logistic regression [foro]. (2019). Stack Exchange. <https://stats.stackexchange.com/questions/229014/matrix-notation-for-logistic-regression>

Gradient descent for logistic regression partial derivative doubt [foro]. (2019). Stack Exchange. <https://stats.stackexchange.com/questions/261692/gradient-descent-for-logistic-regression-partial-derivative-doubt>